

知识解耦与轻量化跨场景自适应波束预测方案深度调研

研究定位与核心判断

把这个方向定位成“半年内可完成、适合冲击 IEEE Globecom / ICC、重点在清晰创新点而不是堆大模型”是可行的，但前提是**不要把论文写成普通的 domain adaptation/fine-tuning 故事**。从 2020–2026 年的代表性工作看，现有文献已经在四条线上铺得比较满：其一是单模态可行性验证，例如 GPS、视觉、LiDAR、Radar 辅助 beam prediction/beam tracking；其二是多模态融合架构升级，例如 multimodal transformer、动态融合、VLM/LLM、量子 transformer；其三是 unseen environment/few-shot transfer，例如 TUNE、MAML、cross-environment transfer learning、DANN-style fine-tuning；其四是缺失模态鲁棒性，例如 missing-modality masking 与 AMBER。真正还没有被系统性打透的，是在**多模态 beam prediction 中，到底什么知识应该跨场景共享，什么知识应该留给新地点的小型 scene-private adapter 去适配**。这正是你这个方向最适合切入的“空白区”。¹

就数据与任务而言，DeepSense6G 是一个**超过 100 万数据点、40+ 场景、同步多模态感知与通信**的大规模真实数据集；2022 Beam Prediction Challenge 使用的是 **scenarios 31–34**，并强调对 **unseen scenario 的 generalization**，挑战输入是**相机/LiDAR/Radar 各 5 帧历史样本 + GPS 2 帧历史样本**，目标是预测 **64-beam codebook** 下的最优波束，官方采用 **DBA score** 作为核心评估指标。公开可见的场景信息还显示：**31 与 32 为 daytime street-level V2I 场景，33 与 34 为 nighttime street-level V2I 场景**。这意味着你天然拥有“**新地点迁移 + 昼夜风格转移 + 多模态互补**”三种论文故事线，但审稿最容易认可的仍然是**what to transfer 而不是 how to fine-tune**。²

最直接的结论是：你的最佳投稿叙事不是“我做了一个更强的 multimodal transformer”，也不是“我做了一个 target fine-tuning trick”。更稳的 Globecom/ICC 叙事应该是：**absolute beam index 对跨场景迁移并不是好的知识单元；更可迁移的是 coarse beam semantics、角度连续性、多模态几何一致性与运动到 coarse group 的映射；而道路几何、基站安装角度、相机 FoV、外观风格、局部反射体分布等应由小型 scene-private adapter 承担**。这一故事能够同时避开 TUNE/MAML/DANN/Cross-Environment TL 的直接重合，也能避开 AMBER 那类“鲁棒融合/缺失模态”主线。³

SOTA查新与去重矩阵

下表把与你方向最相关、且最可能形成“重复嫌疑”的代表性工作压缩成一个去重矩阵。表中“冲突点”不是说不能引用，而是指**如果你的论文标题、摘要和方法卖点跟它落在同一层面，就会被审稿人认为重复**。

论文	年份	数据集	任务	方法核心	是否使用 DeepSense6G	是否跨 场景	是否 少标 注适 应	是否 知识 解耦
Multi-Modal Beam Prediction Challenge 2022: Towards Generalization 4	2022	DeepSense6G 31-34	unseen- scenario beam prediction benchmark	官方任务定义 + 位置基线 + DBA 指标	是	是	否	否
Position Aided Beam Prediction in the Real World 5	2022/2023	DeepSense6G 1-9	GPS-aided beam prediction	分析 GPS 真实 可用性、模型 选择与更合理 指标	是	部分	否	否
Vision-Position Multi-Modal Beam Prediction Using Real Millimeter Wave Datasets 6	2022	DeepSense6G 5-6	vision+GPS beam prediction	双模态融合证 明视觉+位置优 于单模态	是	否	否	否
Radar Aided 6G Beam Prediction: Deep Learning Algorithms and Real-World Demonstration 7	2022	DeepSense6G 实景 V2I	radar-aided beam prediction	雷达信号处理 + DL, 降低 beam training overhead	是	否	否	否
LiDAR Aided Future Beam Prediction in Real-World Millimeter Wave V2I Communications 8	2022/2023	DeepSense6G V2I	future beam prediction / tracking	LiDAR 预测当 前与未来 beam	是	否	否	否

论文	年份	数据集	任务	方法核心	是否使用 DeepSense6G	是否跨 场景	是否少 标注适应	是否知 识解耦
Computer Vision Aided Beam Tracking in a Real-World Millimeter Wave Deployment ⁹	2022	实网视觉场景	future beam tracking	encoder-decoder 由视觉预测未来 beam	部分	否	否	否
Multimodal Transformers for Wireless Communications: A Case Study in Beam Prediction ¹⁰	2023	DeepSense6G Challenge	multimodal beam prediction	CNN + layer-wise transformer token fusion; 图像+GPS 最优	是	部分	否	否
TUNE: Transfer Learning in Unseen Environments for V2X mmWave Beam Selection ¹¹	2023	FLASH + 公开 real/synthetic 数据	unseen-environment beam selection	选最相似 source model + 动态保留层进行 TL	否	是	是	否
Meta-Learning for Image-Guided Millimeter-Wave Beam Selection in Unseen Environments ¹²	2023	FLASH	few-shot unseen beam selection	MAML 学初始化, 测试时少量 samples 快速适配	否	是	是	否
Deep Quantum-Transformer Networks for Multi-Modal Beam Prediction in ISAC Systems ¹³	2024	DeepSense6G V2I	multimodal beam prediction / zero-shot testing	量子层 + transformer, 追求更强表示与 zero-shot 性能	是	是	否	否
Robust Multimodal Beam Prediction With Missing Modality ¹⁴	2025	未见明确 DeepSense6G	missing-modality beam prediction	随机 masking + missing-modality imputation + channel attention	未明确	否	否	否

论文	年份	数据集	任务	方法核心	是否使用 DeepSense6G	是否跨 场景	是否 少标 注适 应	是否知 识解 耦
Multi-Modal Sensing-assisted Beam Prediction using Real-World Dataset ¹⁵	2025	DeepSense6G/ Challenge数据	multimodal beam prediction	ResNet-SE + Plformer, 提升精度并降低训练时间	是	未强调	否	否
Cross-Environment Transfer Learning for Location-Aided Beam Prediction in 5G and Beyond Millimeter-Wave Networks ¹⁶	2025	ray-tracing 两个城市环境	cross-environment transfer learning	reference gNB 模型迁移到 target gNB, 5% target fine-tuning	否	是	是	否
A Deep Transfer Learning-Based Low-overhead Beam Prediction in Vehicle Communications ¹⁷	2025	仿真车联网	DANN-style transfer learning	fine-tuning 时加 domain classifier 抽取 domain-invariant feature	否	是	是	否
Advancing Multi-Modal Beam Prediction With Cross-Modal Feature Enhancement and Dynamic Fusion Mechanism ¹⁸	2025	摘要未明确 DeepSense6G	multimodal beam prediction	MLDA + CMFE + uncertainty-aware dynamic fusion	未明确	未强调	否	否
When VLM Meets Beam Prediction: A Multimodal Contrastive Learning Framework ¹⁹	2025	DeepSense6G	multimodal beam prediction	图像-LiDAR 对比预训练 + 位置作为文本 prompt	是	未强调	否	否

论文	年份	数据集	任务	方法核心	是否使用 DeepSense6G	是否跨 场景	是否少 标注适应	是否知 识解耦
AMBER: An Adaptive Multimodal Mask Transformer for Beam Prediction with Missing Modalities ²⁰	2025/2026	DeepSense6G	missing-modality robust beam prediction	missing-modality-aware mask transformer + CMA + temporal embedding	是	未 强 调	否	否

从审稿人视角，**最强重复风险**来自四类工作。第一类是 **TUNE / Cross-Environment TL / DANN-style 组合**：它们已经覆盖了“unseen environment + limited target data + fine-tuning/适配”这条路，但本质上都把 transfer 当作“迁整个表示或者迁部分层”，没有回答**哪些知识该迁移、哪些不该迁移**。如果你的摘要还写成“limited labels in target + adaptation to unseen scenario”，会非常危险。 ²¹

第二类是 **MAML / meta-learning**。它解决的是“快速适配的初始化参数”，不是“具有物理含义的知识分工”。只要你不把核心 claim 写成“few-shot meta-adaptation for unseen beam selection”，并且不把 adaptation 的本体说成“faster convergence from learned initialization”，你就能比较稳地避开它。你的进路应该是：**coarse beam semantics 天生更 transferable，而 fine beam refinement 天生更 site-specific**。 ¹²

第三类是 **multimodal fusion 升级线**，包括 Multimodal Transformers、QTN、JCN 2025、CMFE、VLM/VLM-like 方法。它们都在证明“更强的融合网络更准确”，但很少把**新地点 adaptation**做成核心问题。你要明显区别于它们：**backbone 轻量、可复现、可复用；创新点不在 fusion 结构，而在知识解耦和 target-side 小参数更新**。 ²²

第四类是 **missing modality robustness**，尤其 AMBER。这条线非常容易把论文带偏，因为一旦你开始强调 modality masking、fusion token、模态缺失训练策略，审稿人会立刻拿 AMBER 对你。最稳妥的做法是：**把缺失模态只放在 robustness benchmark 中，证明你的 decoupling 方法在模态噪声下仍然稳，不把它作为主创新**。 ²³

科学问题重定义

Q1：为什么普通的 domain-invariant representation 不适合毫米波 beam prediction？

问题定义是：beam prediction 的标签并不是纯视觉分类标签，而是由**传播几何、基站朝向、遮挡结构、局部反射体、设备 FoV 与 codebook 映射**共同决定的结果；因此“全表示域不变”会同时抹掉一部分**必须保留的 scene-specific 判决信息**。物理直觉上，毫米波窄波束强依赖 LOS/NLOS 与环境几何，DeepSense challenge 本身就是为了研究 unseen scenario generalization 而设计；Cross-Environment TL 也明确指出 mmWave propagation 具有**highly site-specific**的特点；而 DANN-style recent work 仍然把目标写成“抽 domain-invariant features”，这对于 beam prediction 这种“粗语义可共享、细映射不可共享”的任务来说过于粗暴。本文的切入点因此不是“让所有特征都 invariant”，而是**只让 coarse beam semantics invariant，让 fine refinement 明确由 private branch 承担**。 ²⁴

Q2: 为什么 coarse beam semantics 比 absolute beam index 更适合跨场景迁移?

绝对 beam index 在不同地点、不同基站安装角、不同 FoV 与不同遮挡物分布下并不稳定；但相邻 beam 的角度连续性、粗粒度 beam sector/group 的物理语义、以及“运动趋势→coarse beam group”映射通常更稳定。官方 challenge 之所以采用 DBA 而不仅是 Top-k，就是因为预测落在相邻 beam 上时，在物理接收功率上并不一定是灾难性错误；challenge 论文和后续指标分析都强调，Top-k 这种纯分类指标不足以反映 beam 任务的物理语义，DBA 与 power ratio 相关性更高。换言之，absolute beam class 不是最适合 transfer 的知识单元，coarse beam semantics 才是。本文的切入点是把监督从“单层 absolute class CE”改写成“coarse group + fine offset”的层次监督，并只在 coarse group 空间做 prototype alignment。 ²⁵

Q3: 为什么新地点适应应该只更新极小的 scene-private adapter，而不是 full fine-tuning?

现有 unseen-environment 方案大多依赖 target fine-tuning、层选择迁移或 meta-learned initialization；这些方法虽然有效，但解释方式仍然是“目标域来了以后把原模型再调一遍”。TUNE 已经做了“动态保留哪几层”；Cross-Environment TL 已经做了“少量目标样本 fine-tune 到 target gNB”；MAML 已经做了“few-shot 快速更新”；AMBER 与 JCN 2025 等则进一步把 backbone 做得更复杂。对 Globecom/ICC 投稿来说，如果你再走 full fine-tuning 路线，只会得到“又一个 adaptation trick”的评价。本文应该把问题重新写成：shared branch 已经学到跨场景共享规律，因此目标域只需更新 scene-private adapter 与少量 prototype/normalization 参数，即可恢复 target-specific 细粒度映射。这比 full fine-tuning 更节省参数，更容易复现，也更有物理可解释性。 ²⁶

完整方法框架设计

我建议把整篇论文的方法统一命名为一条主线：Shared-Private Knowledge Decoupling + Hierarchical Beam Semantics + Lightweight Target Adapter + Coarse-Prototype Alignment。这里最重要的不是模块越多越好，而是每个模块都服务于同一个论点：跨场景要迁移 coarse semantics，不要强行迁移 fine mapping；新地点只更新 scene-private correction。

在 backbone 上，不建议再做很重的 BEV fusion 或大尺寸 transformer。基于 challenge 输入格式与现有最强方法的复杂度，建议采用一个可复现的轻量模态编码 + 轻量 token fusion 框架：RGB 用 MobileNetV3-Small 或 EfficientNet-B0 级别编码器，输入下采样到 224×224 ；LiDAR 不走重型 point transformer，而采用 range-view/front-view 投影后的轻量 2D CNN；Radar 先构造 range-angle map，再用 ResNet10/18-lite；GPS 只用两帧位置、相对位移、速度方向与到 BS 的相对极坐标做 2-3 层 MLP；如果想加入历史 beam index，只把它作为可选输入，不作为主版本依赖，以免被质疑和 beam tracking 文献混淆。时间建模上，不必堆大时序 transformer：每个模态先做浅层 temporal conv 或单层 GRU，再把模态 token 喂给一个 2-layer、hidden size 256 的 tiny fusion transformer 或 gated token mixer。这样做的理由很简单：现有文献已经反复证明多模态融合有效，但也已经把“更复杂的融合器”做得很多了；你的论文不应把创新点押在 fusion 器上。 ²⁷

形式化地，设第 m 个模态的输入序列为 $\mathbf{x}_{1:T_m}^{(m)}$ ，模态编码器为 f_m ，时序聚合器为 t_m 。则模态级时序特征为

$$\mathbf{z}^{(m)} = t_m(f_m(\mathbf{x}_{1:T_m}^{(m)})), \quad m \in \{\text{RGB, LiDAR, Radar, GPS, BeamHist}\}.$$

将所有模态特征投影到统一维度后，得到融合表示

$$\mathbf{h} = F(\{\mathbf{W}_m \mathbf{z}^{(m)} + \mathbf{e}_m\}_m),$$

其中 F 是轻量 token fusion 模块， $\mathbf{e}_m$ 是模态类型嵌入。然后做 shared/private 分解：

$$\mathbf{c} = E_c(\mathbf{h}), \quad \mathbf{s} = E_s(\mathbf{h}),$$

其中 $\mathbf{c}$ 承担跨场景可共享的 coarse semantics， $\mathbf{s}$ 承担 scene-private geometry/style/fine correction。推荐维度配置为 $d_h = 256$, $d_c = 128$, $d_s = 64$ ，故意让 private branch 比 shared branch 更窄，避免 private 分支“吞掉全部信息”。

beam label 不建议继续用单层 64 类 one-hot 直接分类。更合理的是构造**层次化 beam semantics**。设 codebook 大小为 B (challenge 中 $B = 64$)，每组包含 K_0 个相邻 beam，则 coarse group 数为 $G = B/K_0$ 。对 beam index $b \in \{0, \dots, B-1\}$ ，定义

$$g = \left\lfloor \frac{b}{K_0} \right\rfloor, \quad \delta = b - gK_0.$$

coarse head 只看 $\mathbf{c}$:

$$p(g|\mathbf{c}) = C_g(\mathbf{c});$$

fine head 看 $[\mathbf{c}, \mathbf{s}, \text{Emb}(g)]$:

$$p(\delta|\mathbf{c}, \mathbf{s}, g) = C_\delta([\mathbf{c}; \mathbf{s}; \text{Emb}(g)]).$$

最终 beam 分布可写成

$$p(b) = p(g) p(\delta|g), \quad b = gK_0 + \delta.$$

如果你想再增加一点物理味道，可以把相邻 beam 的 steering angle 当作顺序先验，在 fine head 上使用 **circular label smoothing / angular-aware loss**，而不是普通 CE。

关于 K_0 的选择，我会直接建议：**主设定用 $K_0 = 8$** ，并以 $K_0 \in \{2, 4, 8, 16\}$ 做消融。原因是非常明确的。 $K_0 = 2$ 时 coarse group 太细，shared branch 仍容易背 scene-specific 细映射，迁移性弱； $K_0 = 4$ 会比 2 稳，但 coarse semantics 仍不够抽象； $K_0 = 16$ 又太粗，会把太多判别压力推给 private refinement，使 Top-1 容易掉、目标域适配负担加重； $K_0 = 8$ 相当于把 64 beams 压成 8 个 coarse sectors，通常最符合“可共享粗语义 + 需适配精细偏移”的分工。预计它对 Top-3/Top-5/DBA 的收益会比对 Top-1 更稳定，但如果 private adapter 设计得好，Top-1 不应明显受损。更一般地，若 codebook 大小变化，建议让 coarse group 数 G 保持在 **8-16** 之间，而不是固定 K_0 数值。

在解耦约束上，建议主损失写成

$$\mathcal{L} = \mathcal{L}_{\text{hier}} + \lambda_{\text{orth}} \mathcal{L}_{\text{orth}} + \lambda_{\text{hsic}} \mathcal{L}_{\text{hsic}} + \lambda_{\text{scene}} \mathcal{L}_{\text{scene-priv}} + \lambda_{\text{mi}} \mathcal{L}_{\text{mi}} + \lambda_{\text{rec}} \mathcal{L}_{\text{rec}} + \lambda_{\text{ang}} \mathcal{L}_{\text{ang}} + \lambda_{\text{con}} \mathcal{L}_{\text{supcon}} + \lambda_{\text{proto}} \mathcal{L}_{\text{proto}}.$$

其中层次监督损失

$$\mathcal{L}_{\text{hier}} = \text{CE}(g^{\setminus*}, p(g|\mathbf{c})) + \lambda_\delta \text{CE}(\delta^{\setminus*}, p(\delta|\mathbf{c}, \mathbf{s}, g^{\setminus*})).$$

正交约束用于减少 shared/private 冗余:

$$\mathcal{L}_{\text{orth}} = \left\| \frac{\mathbf{C}^\top \mathbf{S}}{N} \right\|_F^2.$$

为了让 $\mathbf{c}$ 尽量和 scene label 无关，可以在 source 端最小化

$$\mathcal{L}_{\text{hsic}} = \text{HSIC}(\mathbf{c}, y_{\text{scene}}),$$

而为了让 $\mathbf{s}$ 保留 scene-specific 信息，则额外给 $\mathbf{s}$ 接一个 scene classifier:

$$\mathcal{L}_{\text{scene-priv}} = \text{CE}(D_{\text{scene}}(\mathbf{s}), y_{\text{scene}}).$$

这组设计比 DANN 更合理，因为 DANN 对整块特征施加 domain confusion，容易连 fine beam refinement 所需的 site-specific 信息一起压平；而你这里明确规定：**只有 $\mathbf{c}$ 要“与场景无关”， $\mathbf{s}$ 反而必须“与场景有关”**。

互信息最小化可以选一个可实现而不过重的版本，例如用 variational upper bound/CLUB 形式去压低 $I(\mathbf{c}; \mathbf{s})$ 。但从半年落地角度，我建议把它作为**可选项**：主文里保留，主实验只做一版，若训练不稳就把它降级成 appendix ablation。重构损失不要回到原始模态重建，那会显著加大系统复杂度；更稳的做法是重构 fused feature：

$$\hat{\mathbf{h}} = D([\mathbf{c}; \mathbf{s}]), \quad \mathcal{L}_{\text{rec}} = \|\hat{\mathbf{h}} - \mathbf{h}\|_2^2,$$

其作用只是防止 shared/private 退化到“一个分支空掉”。beam-aware smoothness 则建议直接围绕 beam 邻域构造软标签：

$$q_j \propto \exp\left(-\frac{d_{\text{circ}}(j, b^*)^2}{2\sigma^2}\right), \quad \mathcal{L}_{\text{ang}} = -\sum_j q_j \log p(j),$$

这样相邻 beam 被错预测时不会被像普通 CE 那样“一票否决”，更符合 challenge DBA 的物理语义。监督对比损失则只放在 $\mathbf{c}$ 上，以同 coarse group 为正样本，不同 coarse group 为负样本，用来增强 coarse semantics 的聚类性。相关文献已充分说明 Top-k 之外的物理指标、LOS/NLOS 区分和 coarse 邻域语义在 beam 任务中的重要性，因此这样的层次化/平滑化设计是有明确动机的。 ²⁸

为了避免“private branch 偷偷学完所有信息，shared branch 失效”，我建议你在实现上再加三条很关键的机制。第一，**coarse head 只接 $\mathbf{c}$** ，绝不让 $\mathbf{s}$ 直接参与 coarse prediction。第二，给 private 分支更小容量，比如 $d_s = 64$ 而 $d_c = 128$ ，并在 source 训练时对 $\mathbf{s}$ 加 dropout，让 coarse 任务不能依赖 private 特征。第三，在实验中加入**泄漏检测 probe**：用线性 probe 从 $\mathbf{c}$ 预测 scene label、从 $\mathbf{s}$ 预测 coarse group。理想现象是“scene-from- $\mathbf{c}$ ”接近随机，“group-from- $\mathbf{s}$ ”明显弱于“group-from- $\mathbf{c}$ ”。这会极大增强你论文里“不是名义上拆分”的可信度。

在 target adaptation 阶段，建议采用**source-free + 小参数 adapter** 路线。冻结所有模态 encoder、时间模块、fusion 模块、shared encoder 与 coarse head，只更新：private branch 末端的 adapter、fine head 的最后一层、少量 normalization 参数，以及 target prototype bank。推荐的 adapter 形式是最朴素也最稳的 bottleneck residual adapter：

$$A_t(\mathbf{s}) = \mathbf{s} + \mathbf{U} \sigma(\mathbf{V}\mathbf{s}),$$

其中 $\mathbf{V} \in \mathbb{R}^{r \times d_s}$ 、 $\mathbf{U} \in \mathbb{R}^{d_s \times r}$ ， $r \ll d_s$ 。如果你更喜欢 LoRA，也只把 LoRA 加在 E_s 和 C_δ 上，不要碰 shared branch。合理的可训练参数比例是**0.5%-2%**，再高就会被质疑“本质还是 fine-tuning”。这一设计与 TUNE/MAML/Cross-Environment TL 的核心差别也就很清楚了：**他们在学更新模型；你在学更新 scene-private correction。** ²⁹

针对三种 target 设置，可以统一成一个框架。无标签适配时，使用冻结的 source coarse prototypes $\{\boldsymbol{\mu}_g\}_{g=1}^G$ 和 evolving target-private prototypes $\{\boldsymbol{\nu}_g\}_{g=1}^G$ 。source coarse prototype 从 source 训练集的 shared 特征均值构造：

$$\boldsymbol{\mu}_g = \frac{1}{|\mathcal{D}_g|} \sum_{i: y_i^g = g} \frac{\mathbf{c}_i}{\|\mathbf{c}_i\|_2}.$$

对 target 样本 i ，先算 soft assignment

$$\alpha_{ig} = \frac{\exp(\text{sim}(\mathbf{c}_i, \boldsymbol{\mu}_g)/\tau)}{\sum_{g'} \exp(\text{sim}(\mathbf{c}_i, \boldsymbol{\mu}_{g'})/\tau)}.$$

再用高置信样本更新 target-private prototype

$$\boldsymbol{\nu}_g \leftarrow m\boldsymbol{\nu}_g + (1 - m)\bar{\mathbf{s}}'_i, \quad \mathbf{s}'_i = A_t(\mathbf{s}_i), \quad \text{if } \max_g \alpha_{ig} > \eta_g.$$

无标签目标函数可写成

$$\mathcal{L}_{\text{unsup}} = \mathcal{L}_{\text{IM}} + \lambda_p \sum_i \sum_g \alpha_{ig} \|\mathbf{c}_i - \boldsymbol{\mu}_g\|_2^2 + \lambda_{tp} \sum_i \sum_g \alpha_{ig} \|\mathbf{s}'_i - \boldsymbol{\nu}_g\|_2^2 + \lambda_{\text{cons}} \mathcal{L}_{\text{cons}},$$

其中 $\mathcal{L}_{\text{IM}}$ 采用经典的“逐样本低熵 + 批量高多样性”的 information maximization 形式，以防所有样本塌缩到一个 coarse group。极少标签 setting 下，只需在上式上加入少量 target labeled samples 的 hierarchical CE，同时允许标注样本直接锚定 $\boldsymbol{\nu}_g$ 。半监督 setting 下，再加 teacher-EMA 伪标签与强弱增强一致性即可。

这个 prototype alignment 设计的关键是：**只在 coarse semantic space 对齐到 source，而不是直接在 absolute beam class space 做对齐**。这就是你与 generic prototype alignment 最大的区别，也是与现有 beam prediction 文献差异最大的地方。为减轻 confirmation bias，我建议使用三条保险机制：先做 2-3 epoch 的 coarse-only warm-up，不立刻更新 fine offset 伪标签；只使用 coarse confidence 高、且弱增强/模式子集增强下预测一致的样本做 prototype update；prototype 更新采用 class-balanced EMA，保证热门 group 不会压死稀有 group。整个算法可以用如下伪代码概括：

Algorithm: SKD-HBSA Training

Input:

Source labeled set D_s , target set D_t
Frozen lightweight multimodal backbone

Output:

Source model + target private adapter A_t + target prototypes $\{\mathbf{v}_g\}$

Stage A: Source pretraining

for each source batch:
 encode modalities $\rightarrow \mathbf{h}$
 split $\mathbf{h} \rightarrow \mathbf{c}, \mathbf{s}$
 predict coarse group g and fine offset δ
 update source coarse prototypes $\{\boldsymbol{\mu}_g\}$ by EMA on $\mathbf{c}$
 optimize $\mathcal{L}_{\text{hier}} + \mathcal{L}_{\text{orth}} + \mathcal{L}_{\text{hsic}} + \mathcal{L}_{\text{scene-priv}} + \mathcal{L}_{\text{rec}} + \mathcal{L}_{\text{ang}}$ (+ optional $\mathcal{L}_{\text{supcon}}$)

Stage B: Target adaptation

freeze modality encoders, fusion, E_c , coarse head
initialize A_t and target-private prototypes $\{\mathbf{v}_g\}$
for each target batch:
 encode $\rightarrow \mathbf{h} \rightarrow \mathbf{c}, \mathbf{s}$
 $\mathbf{s}' = A_t(\mathbf{s})$
 compute group prediction $p(g|\mathbf{c})$
 compute soft assignment α to source coarse prototypes $\{\boldsymbol{\mu}_g\}$
 if confidence > threshold:
 update $\mathbf{v}_g$ by EMA using $\mathbf{s}'$
 optimize:
 unlabeled: $\mathcal{L}_{\text{IM}} + \mathcal{L}_{\text{proto}} + \mathcal{L}_{\text{cons}}$
 few-shot: + $\mathcal{L}_{\text{hier}}$ on tiny labeled target set
 semi-supervised: + pseudo-label CE + consistency

如果你最终要冲击 Globecom/ICC，我建议主文只保留最有力的四个技术关键词：**hierarchical beam semantics**、**shared-private decoupling**、**lightweight target adapter**、**coarse-prototype alignment**。MI、contrastive、复杂 teacher-student 都可以作为可选增强，不要把论文写成 loss 拼装。

实验协议与评价指标

实验协议一定要比方法更“审稿友好”。DeepSense6G challenge 本身就是为了研究 unseen scenario generalization 而设，scenarios 31–34 都属于 street-level V2I beam prediction 数据；31 与 32 为 daytime，33 与 34 为 nighttime。与此同时，挑战评估采用 DBA score，公开后续分析工作也指出 beam prediction 不能只看 accuracy，尤其 GPS 质量会对多模态预测造成强烈影响，LOS/NLOS 与 beam 邻域语义也会改变指标解释。因此，你的实验协议必须避免两个 reviewer 雷区：**伪 target leakage** 与 **把 mixed-shift 误写成 same-location-only shift**。³⁰

我建议主实验分成四组。第一组是**严格 leave-one-scene-out new-location split**：在 {31, 32, 33, 34} 上做 4 折，每次留 1 个场景为 target，其余 3 个作 source。比如 {31, 32, 33} → 34、{31, 32, 34} → 33、{31, 33, 34} → 32、{32, 33, 34} → 31。这组实验最重要，因为它最贴合 challenge 的“unseen scenario”精神，也最适合验证你的核心 claim：**shared branch 是否真的学到了可转移 coarse semantics**。

第二组是**day/night style-shift split**，但这里必须谨慎命名。就目前公开可见的网页摘要，能确认的是 31/32 daytime、33/34 nighttime；**不能仅凭公开摘要就武断声称 31↔33 或 32↔34 是同一路段同地点**。因此，论文里最安全的写法有两种。若你后续核实场景元数据确实表明存在同地点昼夜对，则报告“same-location different-time”配对实验；若不能核实，就明确写成**day/night style-shift split**：{31, 32} → {33, 34} 与反向 {33, 34} → {31, 32}。这不是文字游戏，而是避免 reviewer 认为你“错误标注 domain shift 类型”。这一点非常关键。³¹

第三组是**few-shot target adaptation split**。对每个 held-out target scene，从 target 中抽取 label budget = 0/5/10/20/50 的有标注样本，其余 target 样本全作为 unlabeled target。这里建议做 5 个随机种子，并优先采用**coarse-group-stratified sampling**，而不是完全随机抽样。原因很直接：如果 10 个样本全落在少数几个 beam neighborhood，few-shot 实验会高度偶然，审稿人会质疑标注预算的公平性。你可以在正文明确说明：当某些 coarse group 在 target 中样本不足时，才退化为 scene-level uniform random。这样 protocol 更严谨，也与你的 hierarchical label 设计一致。

第四组是**cross-modality robustness split**，但它在你这里是副故事，不是主故事。建议包含四种缺失模态 setting：drop camera、drop radar、drop LiDAR、drop GPS；以及四种退化 setting：GPS drift/jump/freeze、相机 blur/over-exposure/partial occlusion、LiDAR sparsification、Radar ghost peak/noise injection。要证明的不是“我比 AMBER 更擅长缺失模态”，而是**你的 knowledge split 在模态退化时仍然能保住 coarse semantics，从而让 adaptation 不至于崩掉**。²³

评价指标不要只放 accuracy。推荐正文主表统一报告：Top-1、Top-3、Top-5、DBA、normalized received power / power ratio、beam power loss (dB)、adaptation time、trainable parameter ratio、性能-标注预算曲线、性能-适配时间曲线、source-to-target generalization gap、robustness under corruption。它们各自对应的论文 claim 其实很明确。Top-1 证明精确 beam 命中；Top-3/Top-5 证明 candidate reduction 能力；DBA 证明你捕捉到了角度邻域语义而不是单纯分类；power ratio/received power/beam loss 证明通信性能意义；adaptation time 与 trainable parameter ratio 证明“轻量 target adaptation”不是口号；budget curve 证明 few-shot 能力；generalization gap 证明 shared branch 的跨场景价值；corruption robustness 则证明 coarse semantics 没有被个别模态绑架。官方 challenge 和后续指标分析都表明 DBA 与 power-ratio 更贴近 beam 任务的物理目标，因此这两个指标必须进主表，而不是只放附录。³²

基线与消融设计

baseline 不能只是“挑几个能跑的”。你这篇论文如果想过 Globecom/ICC，最重要的是让 reviewer 一眼看出：**我知道自己在和哪一类工作比较，并且比较是公平的**。为此，baseline 应分三组组织。第一组是**无 adaptation 或弱 adaptation**：Source-only、Target-only few-shot、Linear probing、AdaBN/BN-stat alignment。第二组是**经典 adaptation**：Full fine-tuning、DANN、MAML、TUNE-style transfer、Cross-Environment TL-style fine-tuning。第三组是**结构拆解 baseline**：普通 multimodal transformer、普通 shared encoder + classifier、prototype-only adaptation、adapter-only adaptation、你的 full method。相关已有工作的适配策略在文献中都有明确原型，因此无需照搬原文 backbone，而应在**相同轻量 backbone** 上复现它们的“策略”，这是最公平也最容易自证的方法。³³

公平比较原则建议在论文中写得非常具体。所有 baseline 使用相同数据划分、相同 source scenes、相同输入模态集合、相同数据增强、相同 optimizer 预算；few-shot 比较时 target label budget 完全一致；无标签 target adaptation 只允许使用 unlabeled target，不允许额外 source replay；full fine-tuning 与 adapter-based 方法要同时报告**参数更新比例与实际适配时间**；若某 baseline 原文依赖不同 backbone，则在你的实验里固定 backbone，仅保留其核心 adaptation 机制。这样 reviewer 即使不认同你的方法，也很难质疑 protocol。

下面这张消融表足够支撑 Globecom/ICC 主文。重点不是做很多 variant，而是每个 variant 都紧扣一个 claim。

Variant	Hierarchical label	Shared-private	Orthogonality	HSIC	MI minimization	Target adapter	Prototype alignment	Trainable params
V0 Plain MM backbone	否	否	否	否	否	否	否	100%
V1 + Hierarchical label	是	否	否	否	否	否	否	100%
V2 + Shared-private	是	是	否	否	否	否	否	100%
V3 + Orthogonality	是	是	是	否	否	否	否	100%
V4 + HSIC	是	是	是	是	否	否	否	100%

Variant	Hierarchical label	Shared-private	Orthogonality	HSIC	MI minimization	Target adapter	Prototype alignment	Trainable params
V5 + MI min	是	是	是	是	是	否	否	100%
V6 Adapter-only	是	是	是	是	否	是	否	约1%–2%
V7 Prototype-only	是	是	是	是	否	否	是	约0.1%–0.3%
V8 Full method	是	是	是	是	可选	是	是	约1%–2%
V9 Full FT upper-bound	是	是	是	是	可选	否	否	100%

每个消融想证明的逻辑是连贯的。V1 证明**为什么层次语义是更好的 transfer unit**；V2–V4 证明**为什么必须显式 shared/private 而不是靠网络自己学**；V6–V8 证明**为什么目标域只更新 private adapter + prototype 就够了**；V9 则帮助你在 rebuttal 中回答“为什么不直接 full fine-tune”。若 full FT 的收益只比 V8 高 0.5–1.0 个点，但代价大 50–100 倍参数更新和若干倍适配时间，那你的故事就立住了。

创新性评估与投稿风险

以审稿人视角看，这个方向是**足够新的**，但**只有在你把创新点描述对了的前提下**。如果摘要写成“we propose a domain adaptation framework for multimodal beam prediction”，新意会直接掉到中低；如果写成“we propose a lightweight target adapter for few-shot beam prediction”，也会和 TUNE/Cross-Environment TL/MAML 形成明显重叠。真正能让 reviewer 眼前一亮的表述，应当是：**we study what knowledge transfers across scenarios in multimodal beam prediction, and show that coarse beam semantics should be shared while scene geometry and fine index mapping should be adapted with a tiny scene-private adapter**。这个表述与 challenge 论文提出的 unseen-scenario 问题、与现实中 mmWave 传播的 site-specific 特性、与 DBA 指标反映的 beam 邻域语义，是逻辑相连的。 ³⁴

最容易被质疑重复的对象，一是 TUNE/Cross-Environment TL/DANN-style transfer，二是 Meta-learning unseen environment，三是一切“更强融合 backbone”工作。换句话说，你的创新点绝不能表述为“更好的 transfer learning”、也不能表述为“更好的 multimodal fusion”。从风险控制角度，我会建议你从论文中最核心的创新点固定成三句话。第一句：首次把 beam prediction 的 transferable knowledge 显式拆成 coarse beam semantics 与 scene-private fine refinement。第二句：首次把 prototype alignment 限定在 coarse semantic space，而不是 absolute beam class space。第三句：提出只更新极小 scene-private adapter 的 source-free/few-shot adaptation pipeline，而不是做 full fine-tuning。这样就能与现有文献形成清晰边界。 35

方案里最容易显得像“拼装”的模块，是 MI minimization、contrastive loss、scene classifier、prototype alignment、adapter 同时上阵。如果你把它们平铺直叙地全部写进 main method，审稿人会说“this is a bag of tricks”。因此必须把故事线收紧成一个统一框架：因为 absolute beam class 不可直接迁移，所以先抽 coarse semantics；因为 coarse semantics 与 scene-private geometry 混在一起会伤害迁移，所以做 shared/private decoupling；因为 target 只需要恢复 scene-private mapping，所以只更新 tiny private adapter；因为 target 无标签时需要语义锚点，所以只在 coarse semantic space 做 prototype alignment。只要四个模块按这个因果链讲，loss 再多也不会显得散。

如果投稿 Globecom / ICC，我建议删减三样东西。第一，删掉大模型/VLM/LLM 叙事，不要碰。第二，把 MI/contrastive 这种“可有效但不核心”的损失移到附录或补充材料。第三，不要把 missing modality 做成主实验，只保留 robustness 小节。相反，如果未来想往 TVT / TWC 走，可以再加强三样内容：其一，增加一个关于“为何 coarse beam semantics 更可迁移”的理论分析，哪怕只是基于 beam 邻域和 power-ratio/DBA 的 reasoning；其二，增加更系统的 K0 消融、scene-leakage probe 与 source-free/few-shot/semi-supervised 三套完整协议；其三，增加复杂度、适配时间、参数比例和鲁棒性曲线。已有分析型工作已经指出 DeepSense 上单纯靠 GPS 或单一指标很容易得出误导结论，因此更全面的 protocol 与 metric 会显著提升说服力。 36

下面这段 contribution 可以直接写进 Introduction，并且表述上尽量“具体、可验证、避免空泛”：

第一，我们重新定义了多模态波束预测中的跨场景迁移问题，不再把它视为统一的 domain-invariant representation learning，而是提出 coarse beam semantics 可共享、scene-specific geometry 与 fine beam refinement 必须适配的知识分工视角。该分工由层次化 beam label、scene leakage probe 和跨场景 DBA / power-ratio 增益共同验证。

第二，我们提出一个 shared-private knowledge decoupling 框架，使 shared branch 只学习 coarse beam semantics，private branch 只承担场景相关的几何与风格修正；与 DANN-style 全表示对齐不同，该设计具有更清晰的物理解释，并在 unseen target scenes 上显著缩小 source-to-target generalization gap。

第三，我们提出一个 lightweight target adaptation 机制，在 source-free、few-shot 和 semi-supervised 三种 target 设置下，只更新约 1% 量级的 scene-private adapter，并利用 coarse-prototype alignment 对 target shared semantics 进行无标签对齐，从而避免 full fine-tuning 的高成本。

第四，我们在 DeepSense6G scenarios 31–34 上建立严格的 leave-one-scene-out、day/night-style shift、few-shot budget 和 modality corruption 实验协议，并同时报告 Top-k、DBA、power-ratio、adaptation time 与 trainable parameter ratio，全面验证所提方法的泛化性、通信意义与部署效率。 37

半年内可落地的最终执行方案

如果目标是半年内做完、优先冲 Globecom，我建议你直接把项目压缩成一个“最小而完整”的版本，不追求模型炫技，追求 story 一致与结果扎实。

推荐题目可以从下面五个里挑。

Shared and Private Knowledge for Cross-Scenario Multimodal Beam Prediction in New Locations

What to Transfer for Multimodal Beam Prediction in Unseen mmWave V2X Scenes

Hierarchical Beam Semantics and Lightweight Scene-Private Adaptation for Cross-Scenario Beam

Prediction

Coarse-to-Fine Knowledge Transfer for Multimodal Beam Prediction in DeepSense6G

Lightweight Source-Free Adaptation for Multimodal Beam Prediction via Shared-Private Beam Semantics

方法缩写我建议准备三个备选，最终选一个最顺口的：

SKIP-Beam: Shared-private Knowledge decoupling with hierarchical Prototypes for Beam prediction

HiST-Beam: Hierarchical Semantics Transfer for Beam prediction

SPARTA-Beam: Shared-Private Adapter for Target Adaptation in Beam prediction

如果只选一个，我更推荐 **HiST-Beam**，因为它最贴你论文的主线，不会让 reviewer 误以为你在讲复杂系统工程。

模型结构图的文字描述可以这样写：输入为 RGB、LiDAR、Radar、GPS 的短历史序列；每个模态先经过轻量 encoder 与简短时序聚合；融合模块将模态 token 压成一个统一表示 $\mathbf{h}$ ； $\mathbf{h}$ 再被分成 shared 表示 $\mathbf{c}$ 与 private 表示 $\mathbf{s}$ ；shared head 预测 coarse beam group，private-aware head 以 $[\mathbf{c}, \mathbf{s}, g]$ 为输入做 fine offset refinement；source 阶段用 scene-aware decoupling losses 训练 shared/private 分工并构建 source coarse prototypes；target 阶段冻结绝大部分参数，只更新 private adapter、fine head 与 target-private prototypes。

训练流程建议分两步。第一步是 source pretraining：用 source scenes 训练轻量 backbone、hierarchical head 与 shared/private decoupling，保存 source coarse prototypes。第二步是 target adaptation：加载冻结的 source model，在 target 端根据有无标注分别运行 unsupervised / few-shot / semi-supervised 版本，仅更新 scene-private adapter、fine-head 最后一层、少量 normalization 参数和 target-private prototype bank。

测试流程也保持极简。先跑 source-only zero-shot 得到 baseline；再在 target 数据上依据标注预算执行适配；最终在 target test split 报告 Top-1/3/5、DBA、power-ratio、beam loss、adaptation time 与 trainable params。若担心 reviewer 质疑“few-shot label selection 太偶然”，就固定 5 个随机种子并报告均值与标准差。

关键公式其实只需要保留四组，足以支撑整篇论文。

第一组是 shared/private 分解：

$$\mathbf{c} = E_c(\mathbf{h}), \quad \mathbf{s} = E_s(\mathbf{h}).$$

第二组是层次 beam 监督：

$$g = \lfloor b/K_0 \rfloor, \quad \delta = b - gK_0, \quad p(b) = p(g)p(\delta|g).$$

第三组是解耦与场景约束：

$$\mathcal{L}_{\text{dec}} = \lambda_{\text{orth}}\mathcal{L}_{\text{orth}} + \lambda_{\text{hsic}}\mathcal{L}_{\text{hsic}} + \lambda_{\text{scene}}\mathcal{L}_{\text{scene-priv}}.$$

第四组是 target adaptation 的 prototype alignment：

$$\alpha_{ig} \propto \exp(\text{sim}(\mathbf{c}_i, \mu_g)/\tau), \quad \mathcal{L}_{\text{proto}} = \sum_{i,g} \alpha_{ig} \|\mathbf{c}_i - \mu_g\|_2^2 + \beta \sum_{i,g} \alpha_{ig} \|\mathbf{s}'_i - \nu_g\|_2^2.$$

实验表格规划可以直接定成六张主表加三张主图。

主表一：4-fold LOSO new-location 总结果，列出 Source-only、AdaBN、DANN、TUNE-style、Cross-Env TL-style、Adapter-only、Prototype-only、HiST-Beam。

主表二：few-shot budget 0/5/10/20/50 曲线表。

主表三：parameter ratio 与 adaptation time。
主表四：模态缺失与 corruption robustness。
主表五：K0 消融与 decoupling 消融。
主表六：scene leakage probes 与 shared/private 可解释性结果。
主图一：模型结构图。
主图二：Performance vs Label Budget。
主图三：Performance vs Adaptation Time。
如果版面吃紧，主表六可以挪补充材料。

预期结果趋势可以先在论文计划里定下来。最重要的不是绝对数值，而是相对关系。你应该期待：在 0-label target 上，HiST-Beam 相比 Source-only 在 DBA 上有稳定提升，并且优于 DANN/AdaBN 这类“全表示域对齐”；在 5-20 labels 下，HiST-Beam 会迅速逼近 full fine-tuning，但适配时间和参数更新量远低于 full FT；在 Top-1 上，V8 full method 应明显优于 adapter-only 与 prototype-only，证明两者互补；在 Top-3/DBA 与 power-ratio 上，hierarchical label 的收益会比 flat classifier 更稳；在 day/night 或模态噪声下，shared branch 能保住 coarse group，因此 DBA 降幅小于普通 transformer baseline。基于现有文献的性能区间与 challenge 难度，我会把“**zero-shot target 明显优于 Source-only，few-shot 10-20 labels 达到 full FT 大部分收益**”作为最现实也最有说服力的目标，而不是盲目追求全维度 absolute SOTA。 38

代码实现优先级必须非常明确。
优先级最高的是 **P0：数据划分、DBA/Top-k/power-ratio 评估脚本、结果可复现日志**。没有这个，后面都会乱。
接着做 **P1：轻量 source-only backbone**，先用 RGB+Radar+GPS 跑通。
然后是 **P2：hierarchical labels 与 coarse/fine head**。
再做 **P3：shared-private decoupling + leakage probe**。
之后才是 **P4：adapter-based target adaptation**。
最后上 **P5：coarse prototype alignment**。
LiDAR 建议放在 **P6**：先作为增强版，不要一上来就让整个工程复杂度失控。
这种优先级排序能保证你在第 4-6 周就拿到一版可投稿雏形。

一个紧凑的 8-12 周路线图，可以按下面执行。
第 1-2 周：固定 LOSO split、day/night split 命名规范、DBA/power-ratio 实现；复现 Source-only 与官方 baseline。
第 3-4 周：完成轻量 backbone 与 hierarchical label；出第一张主结果表。
第 5-6 周：加入 shared/private 分解、orthogonality、scene classifier、HSIC；跑第一轮消融。
第 7-8 周：实现 adapter-only 与 prototype-only，再合并成 full method；完成 0/5/10/20/50 few-shot 实验。
第 9-10 周：补 DANN、TUNE-style、Cross-Environment TL-style、公平对比；补 trainable params 与 adaptation time。
第 11-12 周：补 corruption robustness、画图、清理论文故事、删掉收益小且训练不稳的额外 loss。
如果进度紧张，第 11-12 周就只补最必要的 robustness 与 K0 消融，先投 Globecom。

最小可发表版本我会这样定义：**RGB+Radar+GPS 三模态；K0=8；shared-private + orthogonality + scene-private supervision + coarse prototype alignment + bottleneck adapter；四折 LOSO + few-shot 0/10/50；baseline 至少包含 Source-only、AdaBN、DANN、TUNE-style、Full FT；指标至少包含 Top-1/Top-3/DBA/power-ratio/adaptation time/params ratio**。这已经足够构成一篇结构完整且创新点清晰的 Globecom/ICC 论文。

强化版期刊版本则可以在六个方向上展开：加入 LiDAR 全模态版本；把无标签、few-shot、半监督三种 adaptation 都做全；加入泄漏 probe 与更多解释性分析；加入更系统的 K0 与 prototype 设计消融；增加 modality corruption/open-world robustness；补一个关于 coarse semantics 可迁移性的理论讨论。这样到 TVT/TWC 层面就更有厚度。

最终一句话总结你的最佳落点：**不要把这篇论文写成“如何微调 target 场景”，而要写成“在多模态毫米波束预测里，究竟什么知识应该迁移，什么知识应该只由一个极小的 scene-private adapter 去承担”**。只要这个主线不偏，这个方向完全有机会在半年内做出一篇不会与 TUNE / MAML / DANN / AMBER / 一般 multimodal transformer 正面重合、且审稿人能看懂其增量价值的 Globecom / ICC 论文。

1 24 25 28 34 37 <https://ar5iv.labs.arxiv.org/html/2209.07519>

<https://ar5iv.labs.arxiv.org/html/2209.07519>

2 <https://arxiv.org/pdf/2211.09769>

<https://arxiv.org/pdf/2211.09769>

3 11 21 26 29 33 35 <https://genesys-lab.org/papers/p1676-gu.pdf>

<https://genesys-lab.org/papers/p1676-gu.pdf>

4 <https://arxiv.org/abs/2209.07519>

<https://arxiv.org/abs/2209.07519>

5 <https://arxiv.org/abs/2205.09054>

<https://arxiv.org/abs/2205.09054>

6 <https://arxiv.org/abs/2111.07574>

<https://arxiv.org/abs/2111.07574>

7 <https://arxiv.org/abs/2111.09676>

<https://arxiv.org/abs/2111.09676>

8 <https://arxiv.org/abs/2203.05548>

<https://arxiv.org/abs/2203.05548>

9 <https://arxiv.org/abs/2111.14803>

<https://arxiv.org/abs/2111.14803>

10 22 38 <https://arxiv.org/abs/2309.11811>

<https://arxiv.org/abs/2309.11811>

12 <https://genesys-lab.org/papers/5544.pdf>

<https://genesys-lab.org/papers/5544.pdf>

13 <https://khu.elsevierpure.com/en/publications/deep-quantum-transformer-networks-for-multimodal-beam-prediction->

<https://khu.elsevierpure.com/en/publications/deep-quantum-transformer-networks-for-multimodal-beam-prediction->

14 https://www.researchgate.net/publication/393932373_Robust_Multimodal_Beam_Prediction_With_Missing_Modality

https://www.researchgate.net/publication/393932373_Robust_Multimodal_Beam_Prediction_With_Missing_Modality

15 https://www.researchgate.net/publication/394985046_Multi-modal_sensing-assisted_beam_prediction_using_real-world_dataset

https://www.researchgate.net/publication/394985046_Multi-modal_sensing-assisted_beam_prediction_using_real-world_dataset

16 <https://arxiv.org/abs/2503.14287>

<https://arxiv.org/abs/2503.14287>

- 17 https://www.researchgate.net/publication/395903227_A_Deep_Transfer_Learning-Based_Low-overhead_Beam_Prediction_in_Vehicle_Communications
https://www.researchgate.net/publication/395903227_A_Deep_Transfer_Learning-Based_Low-overhead_Beam_Prediction_in_Vehicle_Communications
- 18 https://www.researchgate.net/publication/389613391_Advancing_Multi-Modal_Beam_Prediction_with_Cross-Modal_Feature_Enhancement_and_Dynamic_Fusion_Mechanism
https://www.researchgate.net/publication/389613391_Advancing_Multi-Modal_Beam_Prediction_with_Cross-Modal_Feature_Enhancement_and_Dynamic_Fusion_Mechanism
- 19 <https://arxiv.org/abs/2508.00456>
<https://arxiv.org/abs/2508.00456>
- 20 23 <https://arxiv.org/abs/2512.11331>
<https://arxiv.org/abs/2512.11331>
- 27 https://github.com/ITU-AI-ML-in-5G-Challenge/DeepSense6G_TII
https://github.com/ITU-AI-ML-in-5G-Challenge/DeepSense6G_TII
- 30 32 <https://www.deepsense6g.net/challenge2022/>
<https://www.deepsense6g.net/challenge2022/>
- 31 <https://www.deepsense6g.net/scenarios>
<https://www.deepsense6g.net/scenarios>
- 36 <https://opendl.ifip-tc6.org/db/conf/wmnc/wmnc2025/1571178178.pdf>
<https://opendl.ifip-tc6.org/db/conf/wmnc/wmnc2025/1571178178.pdf>