



面向 6G 多模态感知辅助波束预测的 模态缺少鲁棒性研究

汇报人：余超

汇报时间：2026/07/08

目录

01 背景与意义

02 模型架构

03 实验结果与可视化

目录

01 背景与意义


02 模型架构

03 实验结果与可视化

1.1 项目背景



mmWave/THz 通信依赖窄波束提升链路预算，但高移动 V2I/V2V 场景中传统 exhaustive beam sweeping 带来较高时延和开销。现实基础设施侧往往已经有 RGB camera、GPS、LiDAR、radar、mmWave sensing power 等信息，因此可以用多模态 sensing 预测最优 beam，把 beam alignment 从“反应式扫描”转成“上下文感知预测”。



问题：为什么缺失模态重要
多模态 beam prediction 通常依赖 image/radar/LiDAR/GPS，但实际部署时 image 可能不可用，LiDAR/radar 可能质量波动，所以不能只优化 full modality。
修改下，明确立足点

1.2 相关工作

已有方法不足

蒸馏/对齐类：能缓解语义漂移，但容易只做完整模态到缺失模态对齐，缺少 beam 邻近结构。3-5篇(列出文献)，讲讲相比于通用模态缺失，讲讲考虑到beam信息

AMR-Net/CUAF 这类不确定性融合：会根据 entropy/confidence 动态加权 logits，但它主要是 uncertainty-driven，不直接利用 beam 原型结构，也没有 oracle router supervision 明确教 router 当前该信哪个模态。概括下现有模态缺失下的波束预测方法是怎么做的，A(模块)+B(模块)。

目录

01 背景与意义


02 模型架构与创新点

03 实验结果与可视化

2.1 模型概览



C2: Prototype-Aware Supervised Router for Missing-Modality Beam Prediction



创新点1：原型聚类(ours)相对于蒸馏/对齐这类避免模态缺失导致的语义漂移，对于波束预测任务能够获得更多信息，让特征空间保留 beam 邻近结构信息

创新点2：可靠性融合相对于AMR-Net式不确定性加权、平均融合/拼接融合这类缺少beam任务监督的融合方式，对于缺失模态波束预测任务能够额外利用beam原型间隔判断各模态预测是否可靠，并通过oracle router distillation学习“当前缺失模式下该信哪个模态”

如果某些缺失模式更重要，可以给这些 pattern 更高训练权重，如missing-image、radar-only

让融合特征空间变得有 beam 空间关系，而不是乱七八糟只靠分类头硬分

让每个单模态分支都在同一个 beam prototype 空间里可比较，也就是让单模态去靠近融合模态的原型中心。

给出每个模态的权重


定位：不是发明 prototype，也不是发明 uncertainty fusion，而是把 beam prediction 的圆形决策几何引入 missing-modality robustness，并用 prototype-aware oracle-supervised routing 解决不同缺失模式下的可靠模态选择。

训练完以后，prototype bank 就变成一组有意义的 beam 原型中心。


2.1 各模态编码器




Each modality is encoded into a unified M -dimensional feature vector for downstream fusion.




(a) Image encoder. It extracts visual features using a TinyViT-5M backbone and projects them into the unified M -dimensional feature space.



(b) LiDAR encoder. It converts point cloud data into a dense LiDAR map and extracts features using a TinyViT-5M encoder followed by projection.



(c) Radar encoder. It converts raw radar signals into a range-angle map and extracts radar features using a pretrained radar CNN branch.



(d) GPS encoder. It maps longitude and latitude through an MLP into the unified M -dimensional feature space.


2.3 创新点1

Beam-prototype decision-space alignment

Prototype Margin for Beam Prediction


Case 1: High Prototype Margin

large top1-top2 prototype gap $\rightarrow$ reliable modality



Case 2: Low Prototype Margin

small top1-top2 prototype gap $\rightarrow$ uncertain modality



prototype margin = top-1 prototype probability - top-2 prototype probability

$$m_m = p_1 - p_2$$



used as a **reliability feature** by the supervised router

modality feature vector $f_m \in \mathbb{R}^d$ beam prototypes $P_i \in \mathbb{R}^d$ ($i = 1, \dots, B$) top-1 (nearest) prototype top-2 prototype similarity / projection


不将 beam index 视为无序类别，而是利用 beam 的 circular / neighboring structure(先用自己的话说清楚，不要上来就发明一个新的词) 构建 learnable beam prototype bank，并用 Gaussian / circular soft targets 约束各模态与融合特征。这样可在缺失模态下减少 feature-to-decision 的漂移，使剩余模态仍对齐到具有物理邻接意义的 beam 决策空间。(强调beam物理意义，应该是直线，而不是一个圈，请你确认下当前Beam Prototype Alignment Loss 是约束成1个圈还是一条线，哪个更符合beam物理意义)

消融：去掉 prototype alignment loss；去掉 modality prototype loss；去掉 circular soft targets；prototype head 换 classifier head。

2.4 创新点2



Prototype-aware supervised modality routing



AMR-Net: uncertainty-driven fusion

Relies on uncertainty cues (entropy, confidence, divergence) to weight modality logits.



C2: beam-prototype-aware supervised routing

Leverages beam prototype scores (prototype margin) + other cues, with oracle distillation under missing-modality patterns.

不同于 AMR-Net/CUAF 主要依赖 entropy / confidence / divergence 等自估计不确定性加权, C2 引入 beam-prototype margin 作为任务相关可靠性线索, 并用 oracle router distillation 监督 router 学习 “当前 missing pattern 下哪个可用模态最可靠”。推理时无需 oracle, 仅根据可靠性特征和缺失模式进行 masked softmax routing.

消融: 去掉 router supervision; 去掉 prototype margin; 去掉 pattern features; 换成 raw confidence gate; 换成 BPRR / weighted_sum / average fusion.

目录

01 背景与意义

02 模型架构

03 实验结果与可视化

3.1 实验参数




训练场景Deepsense6G 31-34 , MMW Town3 5个场景
输入窗口5, 预测窗口1
输入模态: Image、Lidar、Radar、GPS

3.1 实验结果




Full 表示四个模态都在；Drop1 表示缺 1 个模态；Drop2 表示缺 2 个模态；Drop3 表示只剩 1 个模态。这里每个 Drop 结果都是对应所有缺失组合的平均，比如 Drop2 是 6 种缺两个模态组合的平均。

ADBA: Full vs Drop-count Missing Patterns



Top-1: Full vs Drop-count Missing Patterns



C2 的核心收益不只是完整模态下更强，而是在缺失模态越严重时越稳，特别是在 ADBA 上优势很大，说明原型感知的监督路由能够更好保留 beam 空间的邻接结构和物理连续性。

3.1 实验结果




full 时 Router 主要信 image; missing-image 时权重自动分配给 radar/LiDAR/GPS; single-modality 时 masked softmax 保证只给可用模态权重。

这说明 C2 不是固定融合，而是根据缺失模式动态调整模态可信度。


观察结论：点1 image模态最强 点2... 点3... ..

平均权重图

C2 router weights across single-missing, drop-2, and single-modality patterns




注意：这是经过原型聚类后的各个编码器，如果未经过原型编码器聚类的话，单模态编码器精度：image > gps >> lidar~radar
解释/假设合理原因：GPS 掉得最大是合理的。单独训练时 GPS 可以学到 Scene31-34 中“位置/轨迹到 beam”的 shortcut，所以有 0.4140；但进入 C2 后，GPS 更像辅助可靠性和空间先验，且原型对齐会削弱它的直接坐标 shortcut。也就是说，GPS 的“强”更像数据分布相关 shortcut，不一定是稳健语义特征。此处可补充个可视化 (t-SNE/PCA?)



3.1 实验结果



时刻权重图



未来补充一个图, (此图只有MMW数据集才行, ds6g数据集的gps轨迹太乱了, 效果不好): 将e1-e4换成4个模态的权重, 上色方法使用rbg-a(1、选最高权重的2、融合——炫彩效果), 也仿照这个图, 取几个点给出具体数值

3.2 下一步工作

- 1、确定实验参数，历史窗口5和预测窗口长度1。
- 2、当前只有模态缺失，对数据预处理增加时序缺失，如某几帧不可用
- 3、将MMW设定为主数据集，添加天气变量，进一步增加可靠性融合的意义
- 4、完成所有主要模块的消融实验，证明模块的有效性
- 5、可视化：a 时刻权重图 b 原型聚类类别图 c



敬请老师批评指正！

汇报人：余超

汇报时间：2026/07/08